

A faint, light-gray network graph serves as the background, consisting of numerous small circles of varying sizes connected by thin gray lines.

20 Ιανουαρίου 2018

Data Science Workshop



Golden Gate Pro

Λίγα λόγια

Hello!

Τάσος Βεντούρης

Data Scientist and
Game Designer @
Hattrick Ltd

You can find me at:



@tasosventouris



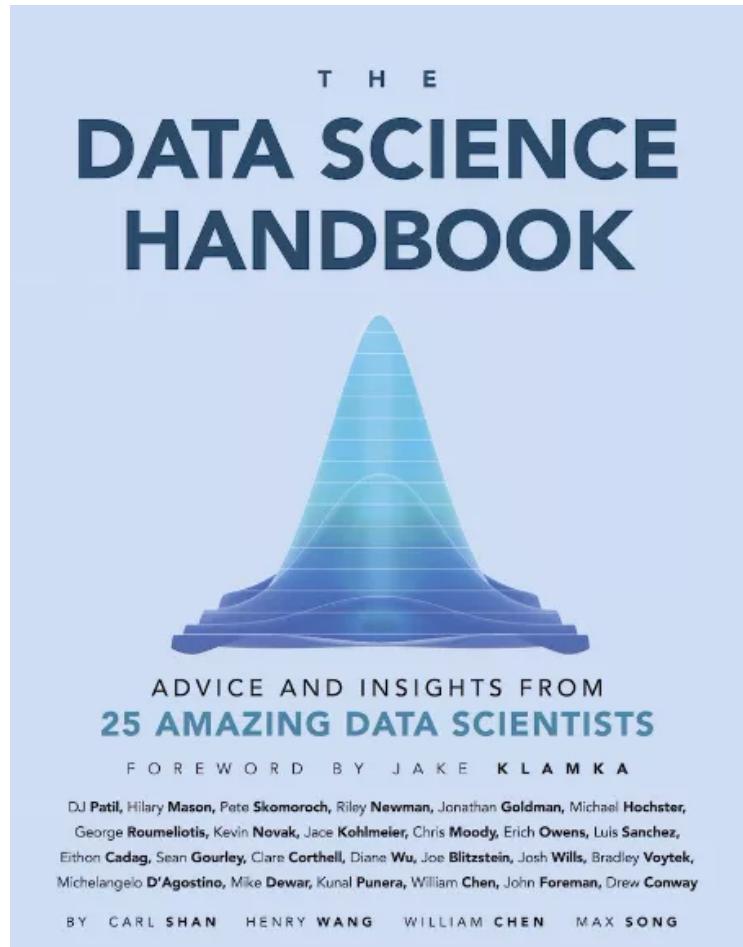
Tasos Ventouris



More About Me!

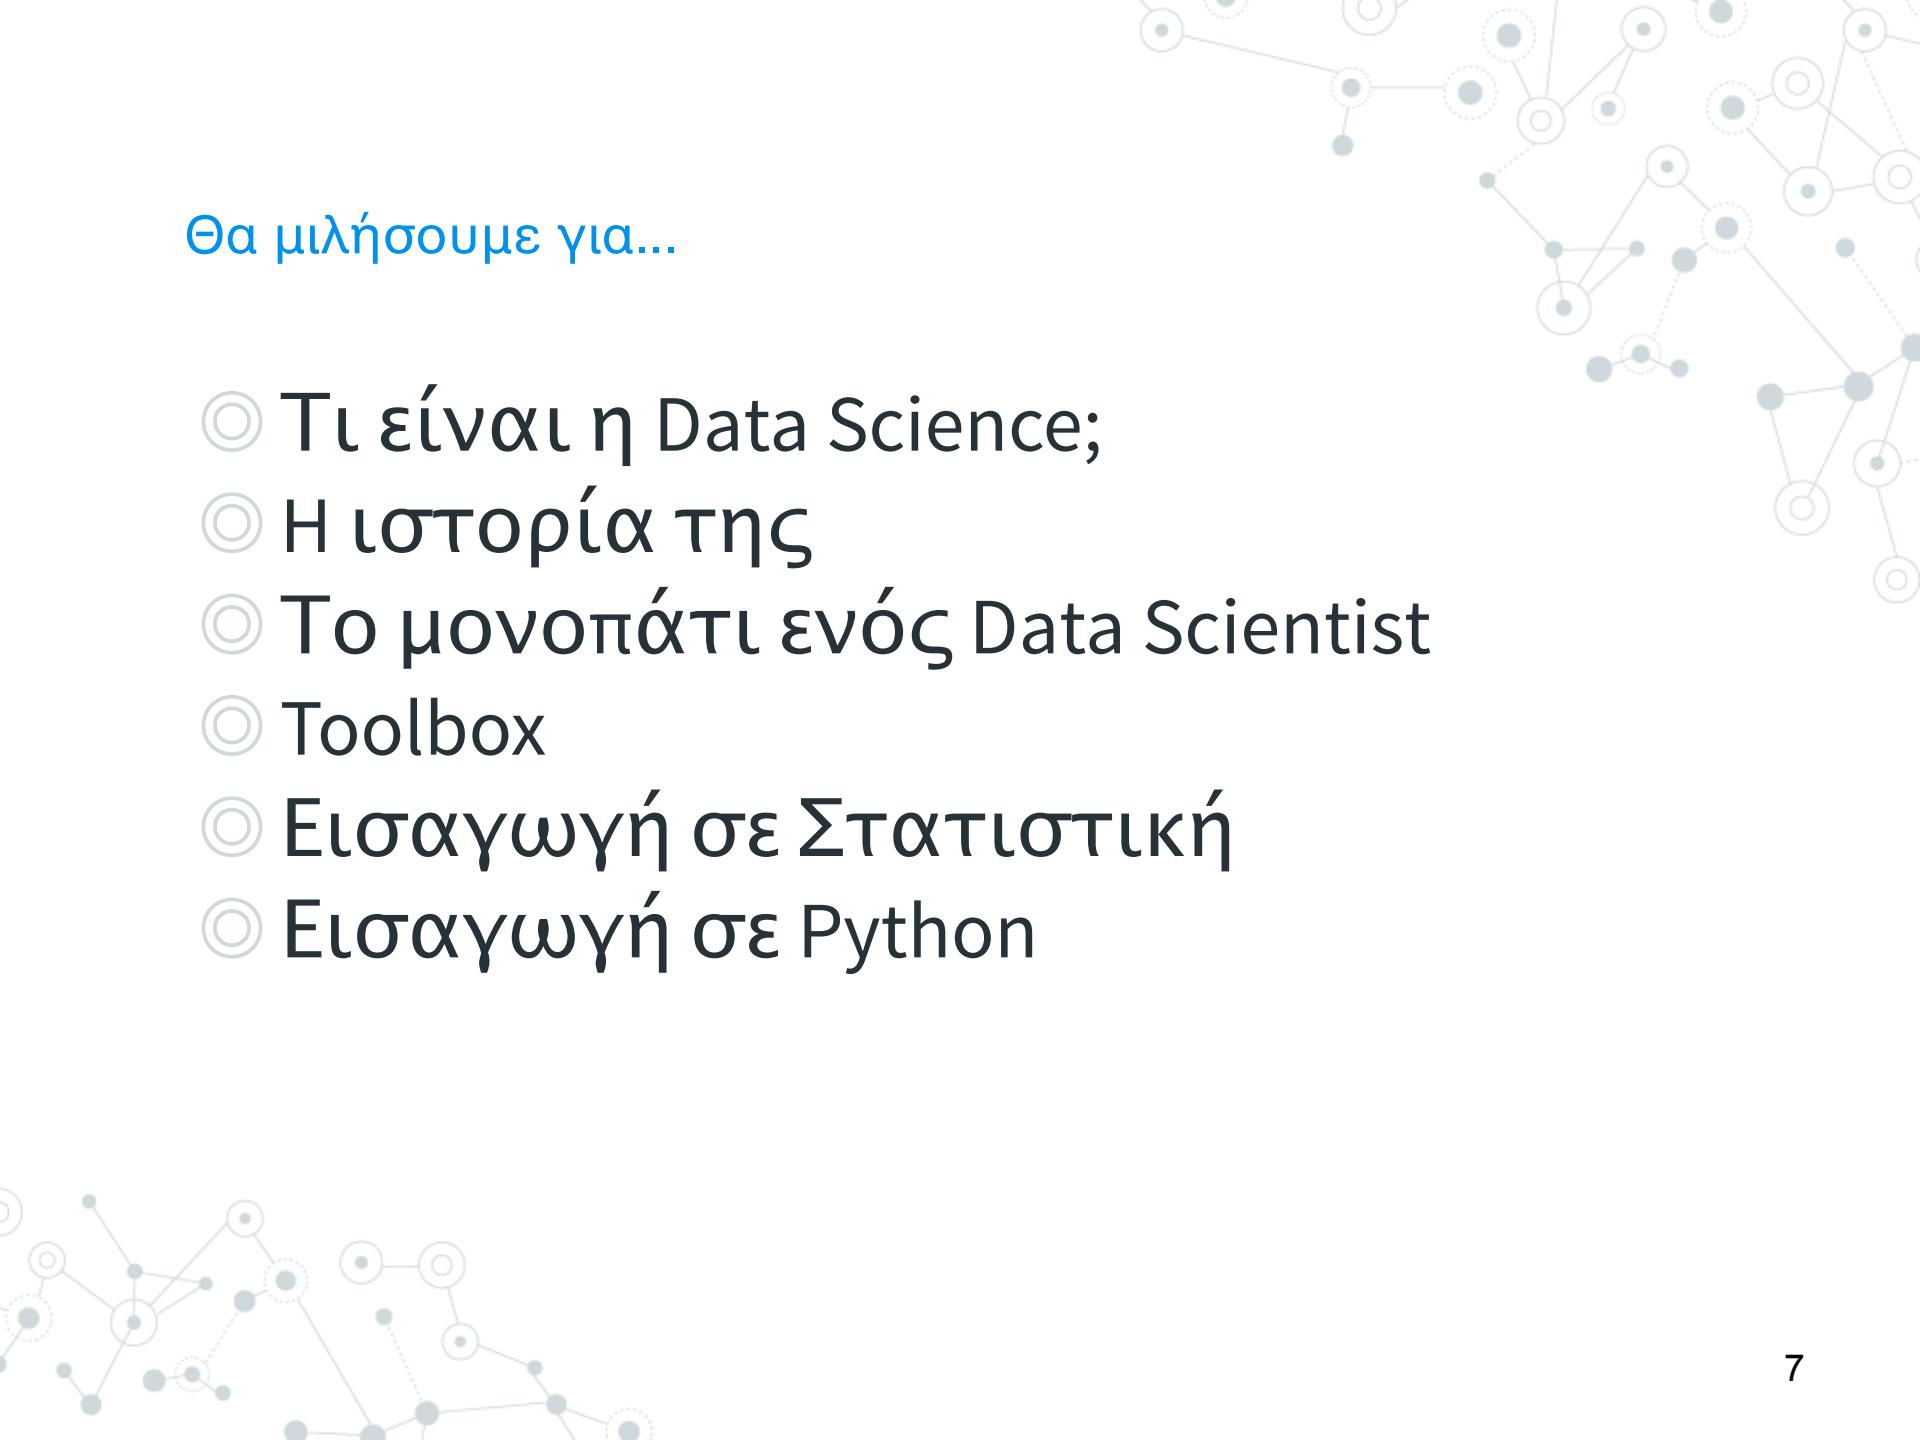
- (2012) BSc Mathematics
- (2014) MSc Web Science
- (2015) Mentor @ Open Knowledge Inter.
- (2016) Offered a PhD in Web Science @ Southampton
- (2016) stackprime
- (2016) Data Scientist @ Hattrick
- (2017) Data Science Degree @ Microsoft

The Data Science Handbook



Day 1

Εισαγωγή 😊



Θα μιλήσουμε για...

- ◎ Τι είναι η Data Science;
- ◎ Η ιστορία της
- ◎ Το μονοπάτι ενός Data Scientist
- ◎ Toolbox
- ◎ Εισαγωγή σε Στατιστική
- ◎ Εισαγωγή σε Python



1.

Data Science

Ή αλλιώς, η Επιστήμη των Δεδομένων. Τι είναι και αν αξίζει να επενδύσω σε αυτήν;

<https://hbr.org/2012/10/data-scientist-the-sexiest-job-of-the-21st-century>

— REPRINT
**Harvard
Business
Review**

DATA

Data Scientist: The Sexiest Job of the 21st Century

by Thomas H. Davenport and D.J. Patil

FROM THE OCTOBER 2012 ISSUE

SUMMARY

SAVE

SHARE

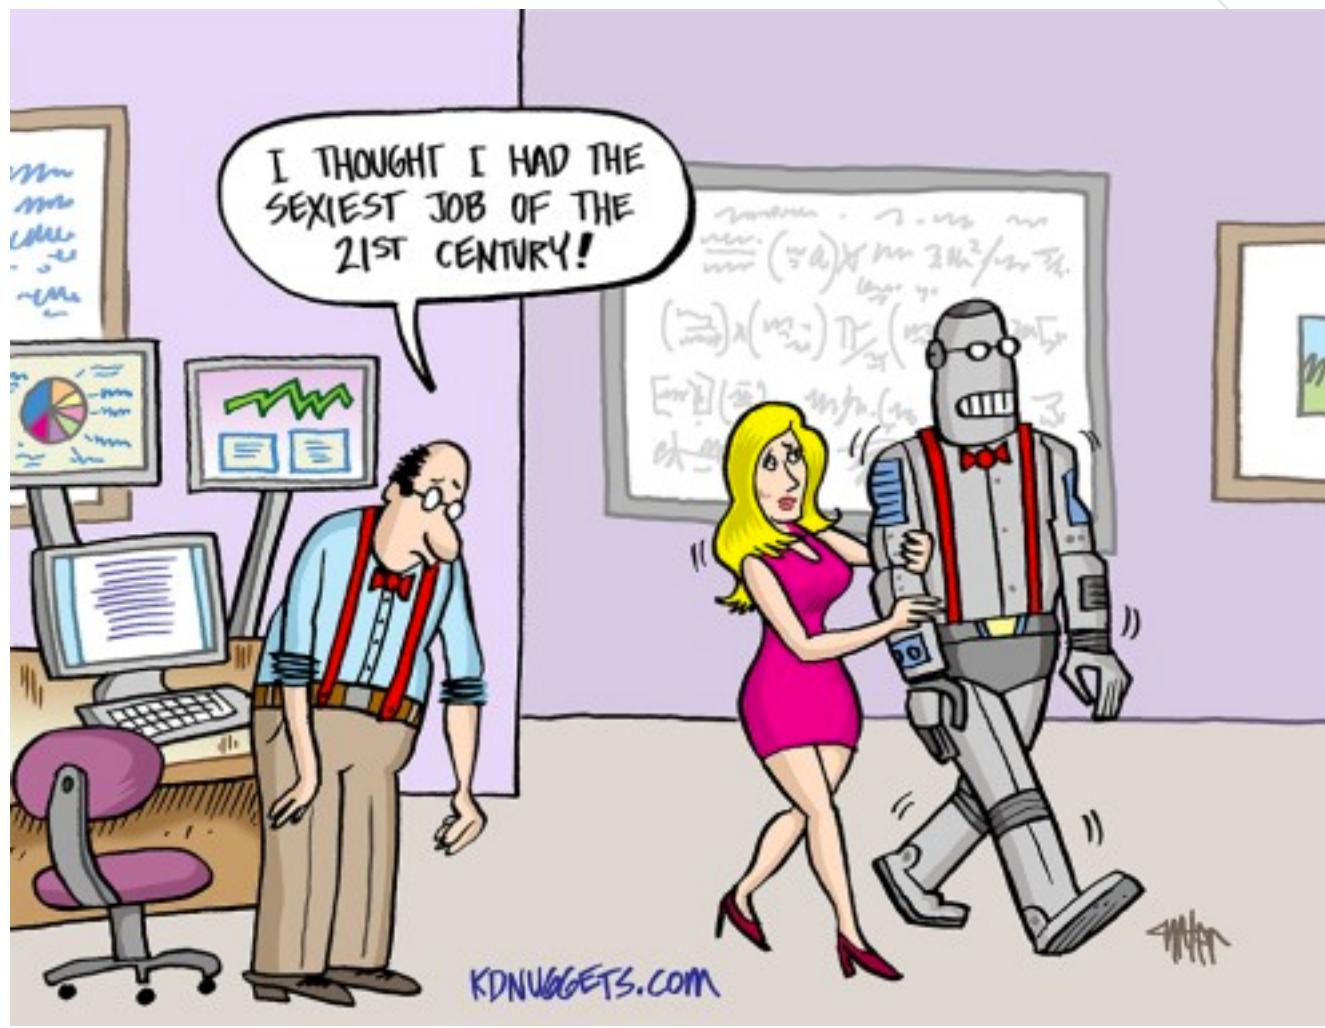
COMMENT 4

TEXT SIZE

PRINT

\$8.95
BUY COPIES

When Jonathan Goldman arrived for work in June 2006 at LinkedIn, the business networking site, the place still felt like a start-up. The company had just under 8 million accounts, and the number was growing quickly as existing members invited their friends and colleagues to join.





“

Η επιστήμη των Δεδομένων είναι ένα **διεπιστημονικό** πεδίο του οποίου αντικείμενο είναι η εξαγωγή της γνώσης από αδόμητα ή δομημένα δεδομένα.

--Wikipedia



“

*A field of Big Data which seeks to provide meaningful information from large amounts of complex data. Data Science combines **different fields of work** in statistics and computation in order to interpret data for the purpose of decision making.*

--*investopedia.com*

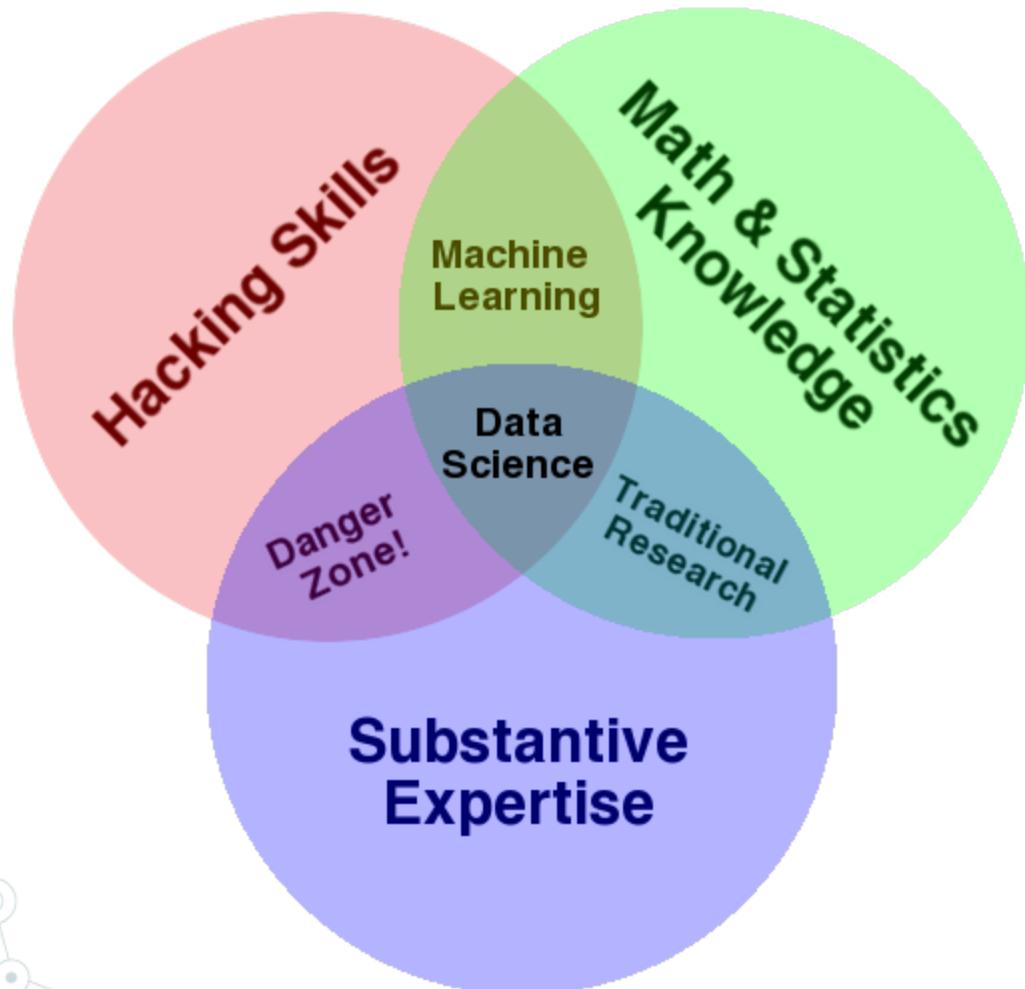


“

The creation of data products

*Data product = Ένα εργαλείο που δημιουργήθηκε με τη χρήση δεδομένων και βιοηθάει στη λήψη αποφάσεων.

My favourite



Data Scientist

Ποιος λοιπόν μπορεί να έχει τον
τίτλο του Data Scientist;



“



Josh Wills
@josh_wills

[Follow](#)



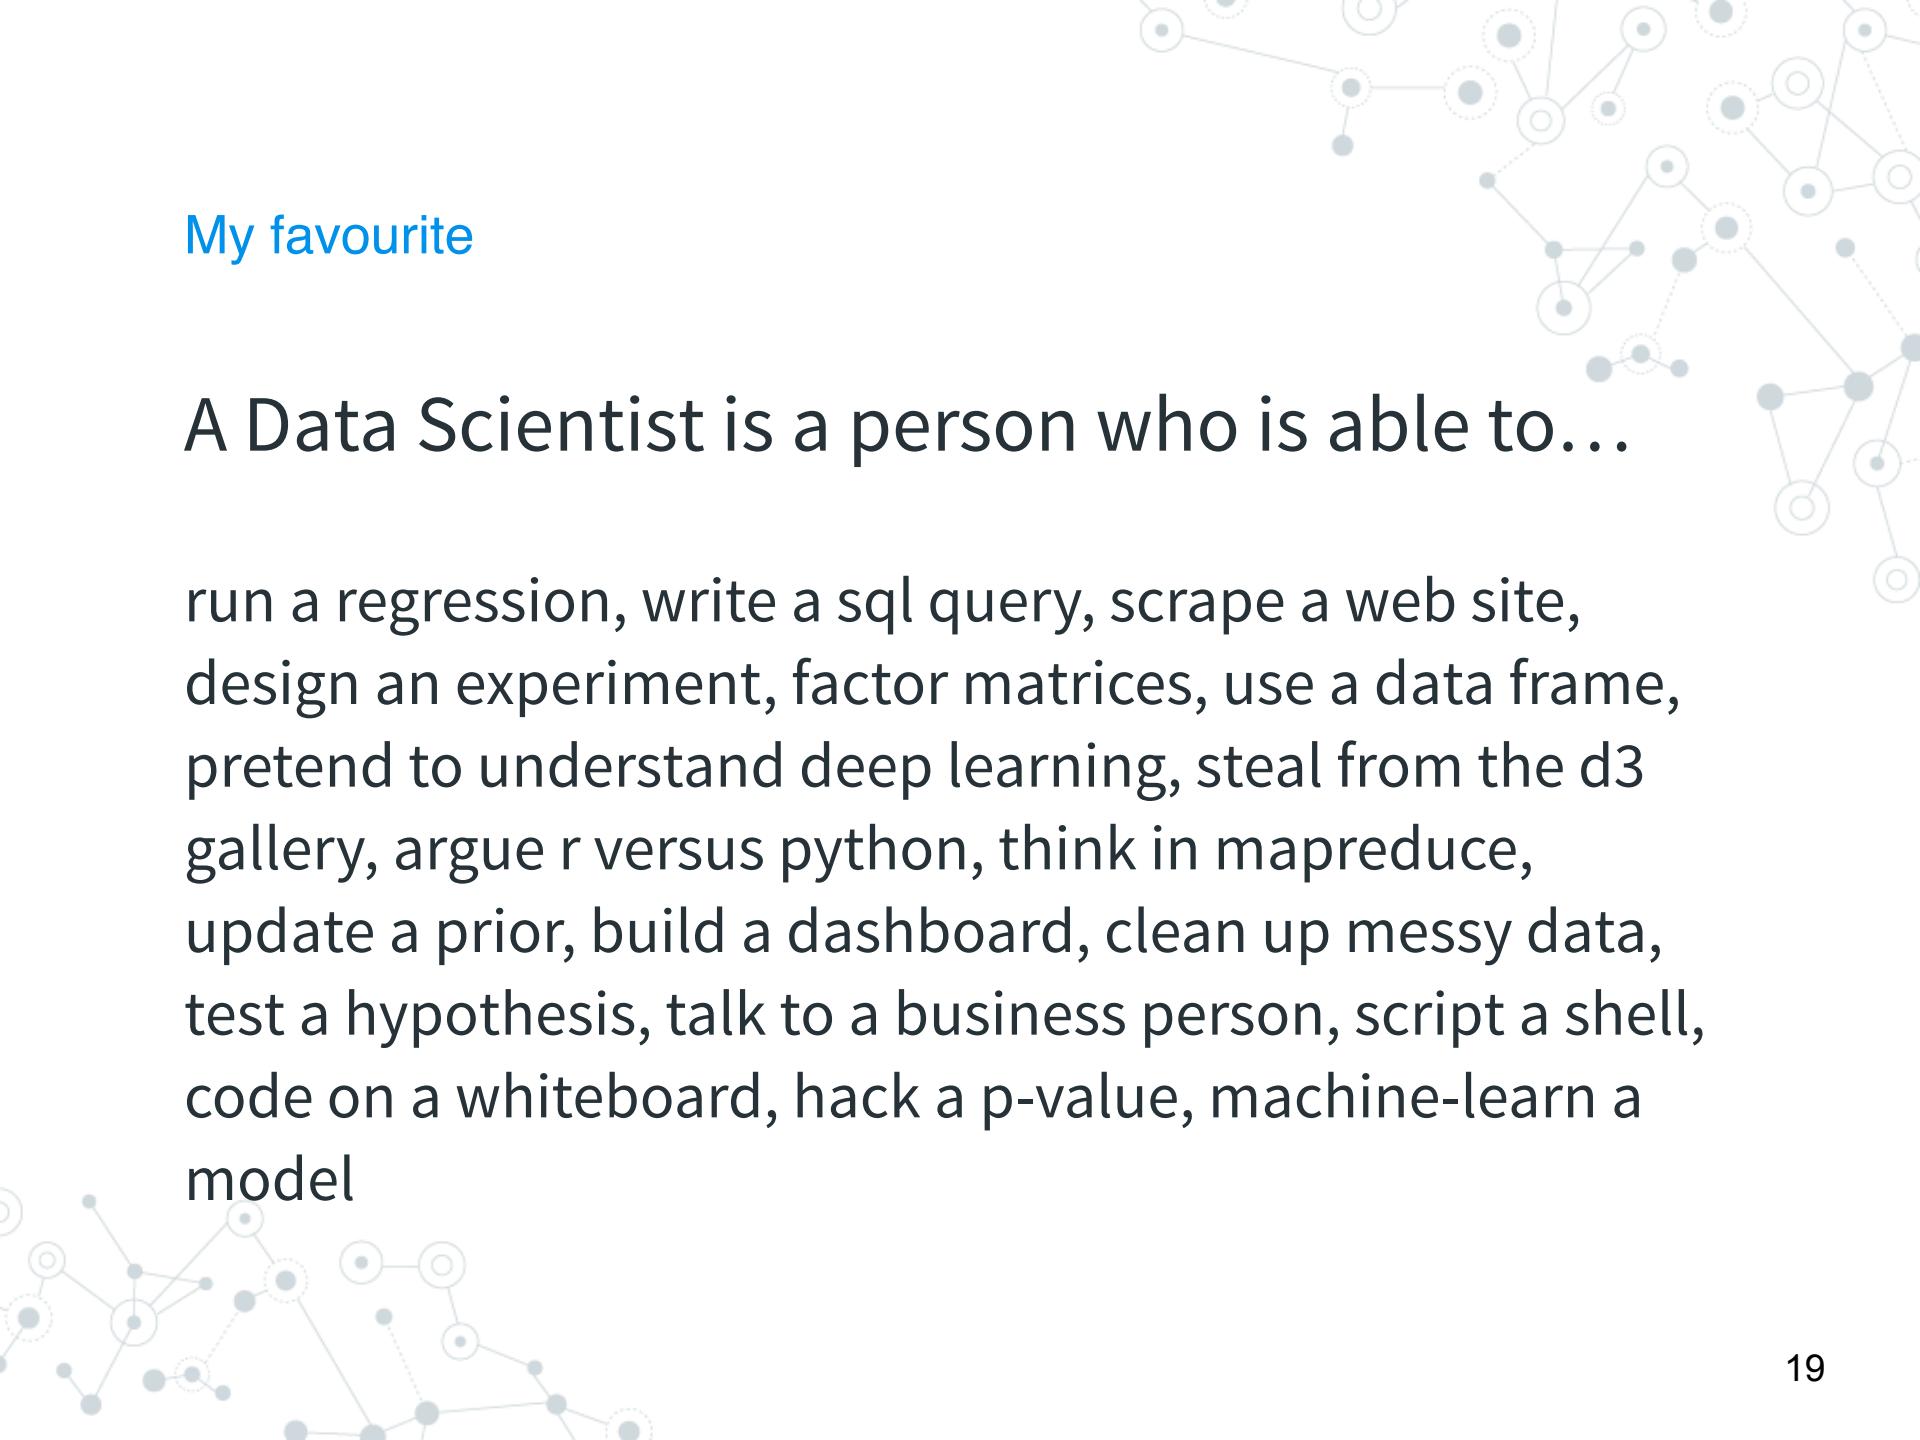
Data Scientist (n.): Person who is better at statistics than any software engineer and better at software engineering than any statistician.



*A Data Scientist is a **statistician**
who lives in San Francisco 😊*

Πικρή Αλήθεια #1





My favourite

A Data Scientist is a person who is able to...

run a regression, write a sql query, scrape a web site,
design an experiment, factor matrices, use a data frame,
pretend to understand deep learning, steal from the d3
gallery, argue r versus python, think in mapreduce,
update a prior, build a dashboard, clean up messy data,
test a hypothesis, talk to a business person, script a shell,
code on a whiteboard, hack a p-value, machine-learn a
model



Πικρή Αλήθεια #2

For the rest...

you are just THE “data-guy”

(or THE “math-guy”)



Ποια είναι η αξία της Data Science;

Τι απάντησαν 5 Data Scientist



“

When you ask me what the value of data science is, it's almost, like explaining the value of water to a fish.

--Media



*We're going to help the business go to new places that it
hasn't yet even thought of going.*

--Biotechnology



“

*If we didn't have a data science capability we would lose
money.*

--Manufacturing



“

We have an asset: it's the data. And what you do with that data dictates whether you'll be differentiated in the future.

--Retail

“

The business realized that, nowadays, we cannot be competitive if we are not data-savvy enough.

--Banking



2.

Η ιστορία

Πως ξεκίνησαν όλα;

Χρονοδιάγραμμα

- 1960 - Computer Science = Data Science από Peter Naur
- 1974 - Πρώτη φορά σε δημοσίευση από Peter Naur
- 1996 - Συνέδριο με τίτλο “Data Science, classification, and related methods”
- 1997 - Ομιλία του Jeff Wu με τίτλο “Statistics = Data Science?”
- 2001 - William S. Cleveland χρησιμοποίησε τη Data Science ως ανεξάρτητο όρο σε άρθρο της “International Statistical Review”
- 2002 - Committee on Data for Science & Technology. Νέο περιοδικό με τίτλο Data Science Journal
- 2003 - The Journal of Data Science από Columbia University
- 2008 - DJ Patil & Jeff Hammerbacher χρησιμοποίησαν τον τίτλο Data Scientist
- 2012 - Άρθρο από Harvard Business Review με τίτλο “Data Scientist: The Sexiest Job of the 21st Century”

Data Science ≠ Big Data

Apollo XI, 1969

64Kb

SkyDive Stratos, 2012

Δεκάδες Gigabytes

3.

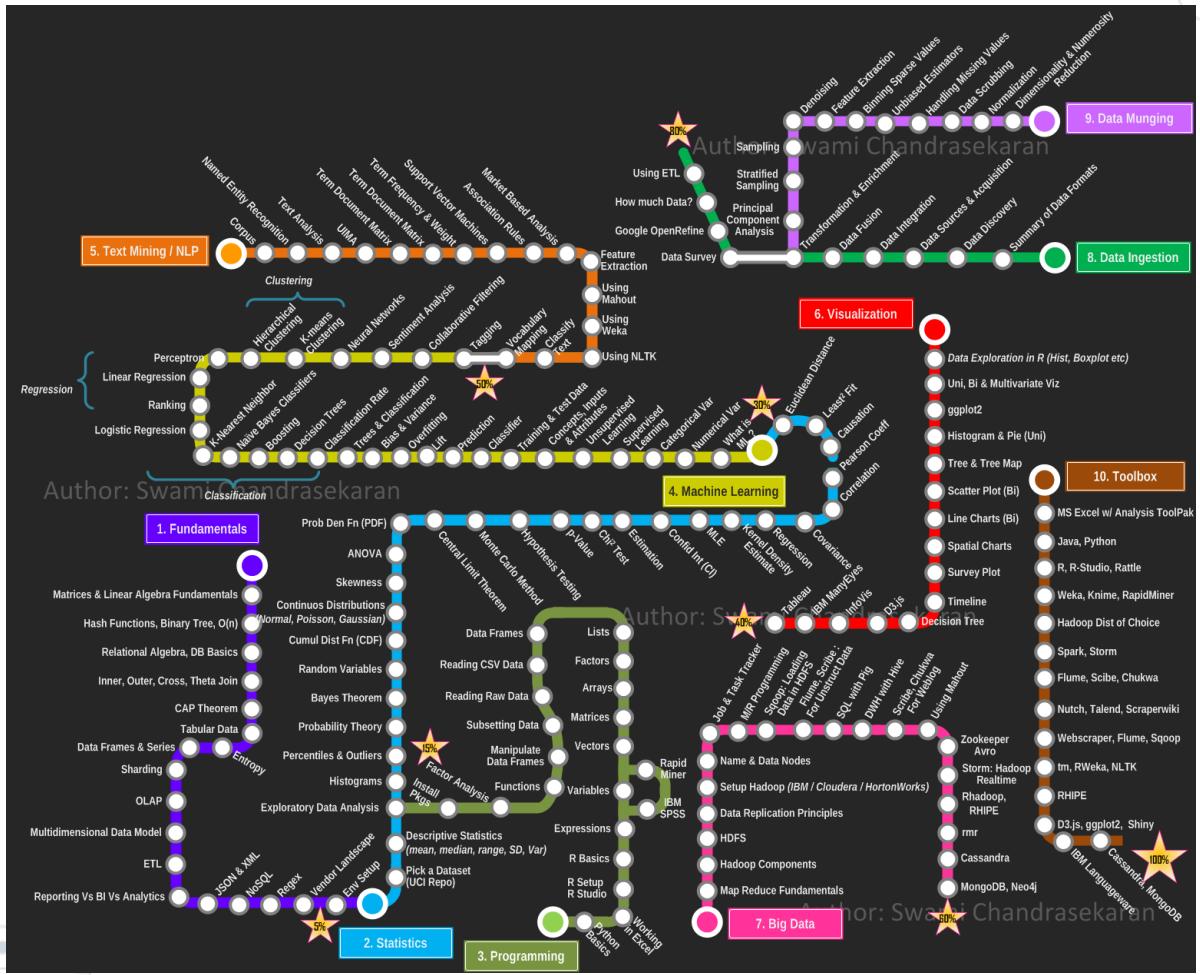
To μονοπάτι ενός Data Scientist

Yeah! I had a skill up...

Πικρή Αλήθεια #3



Το μυοπάτι του Data Scientist



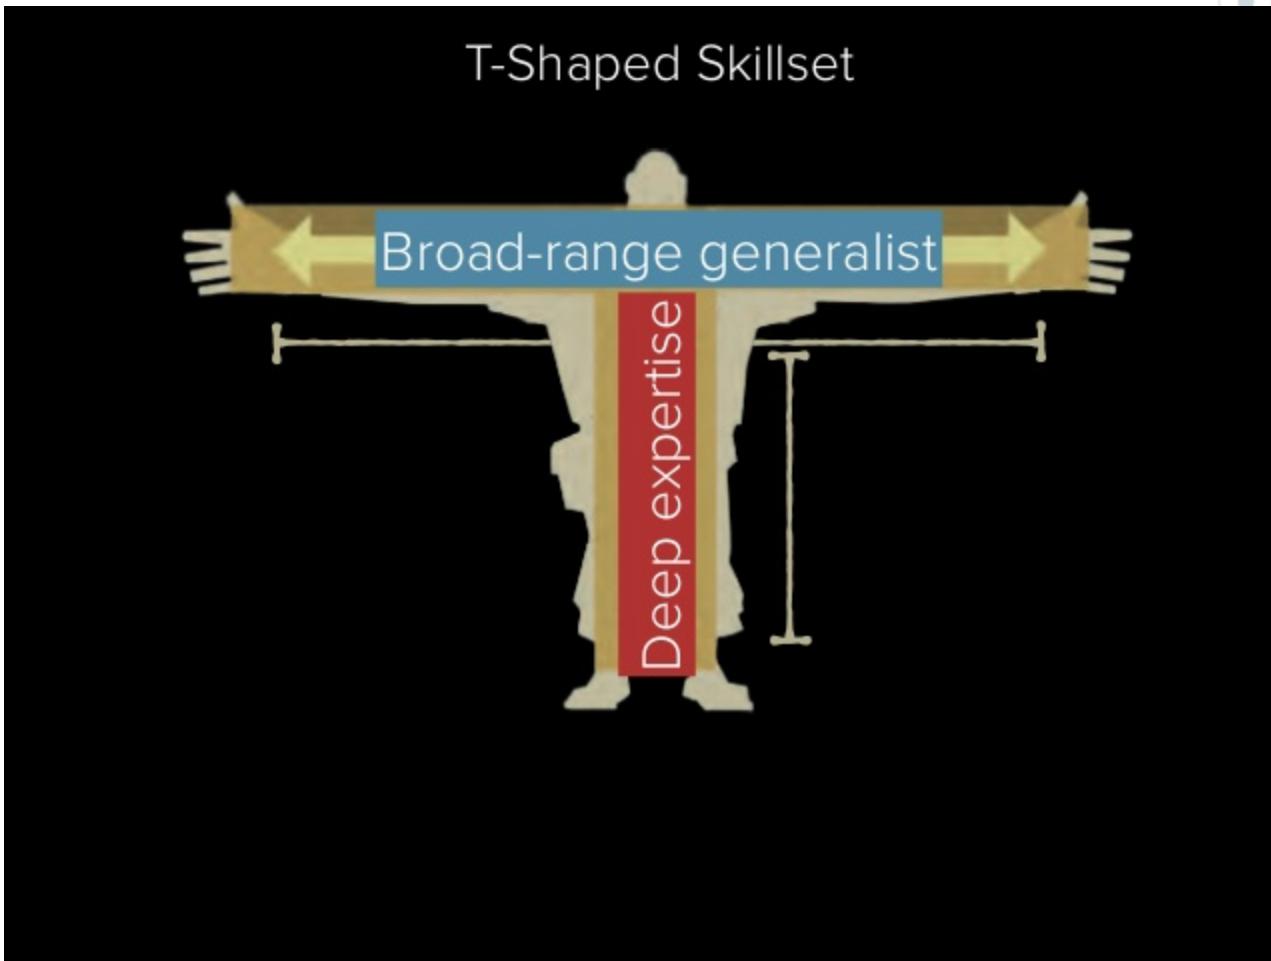
Focus on....

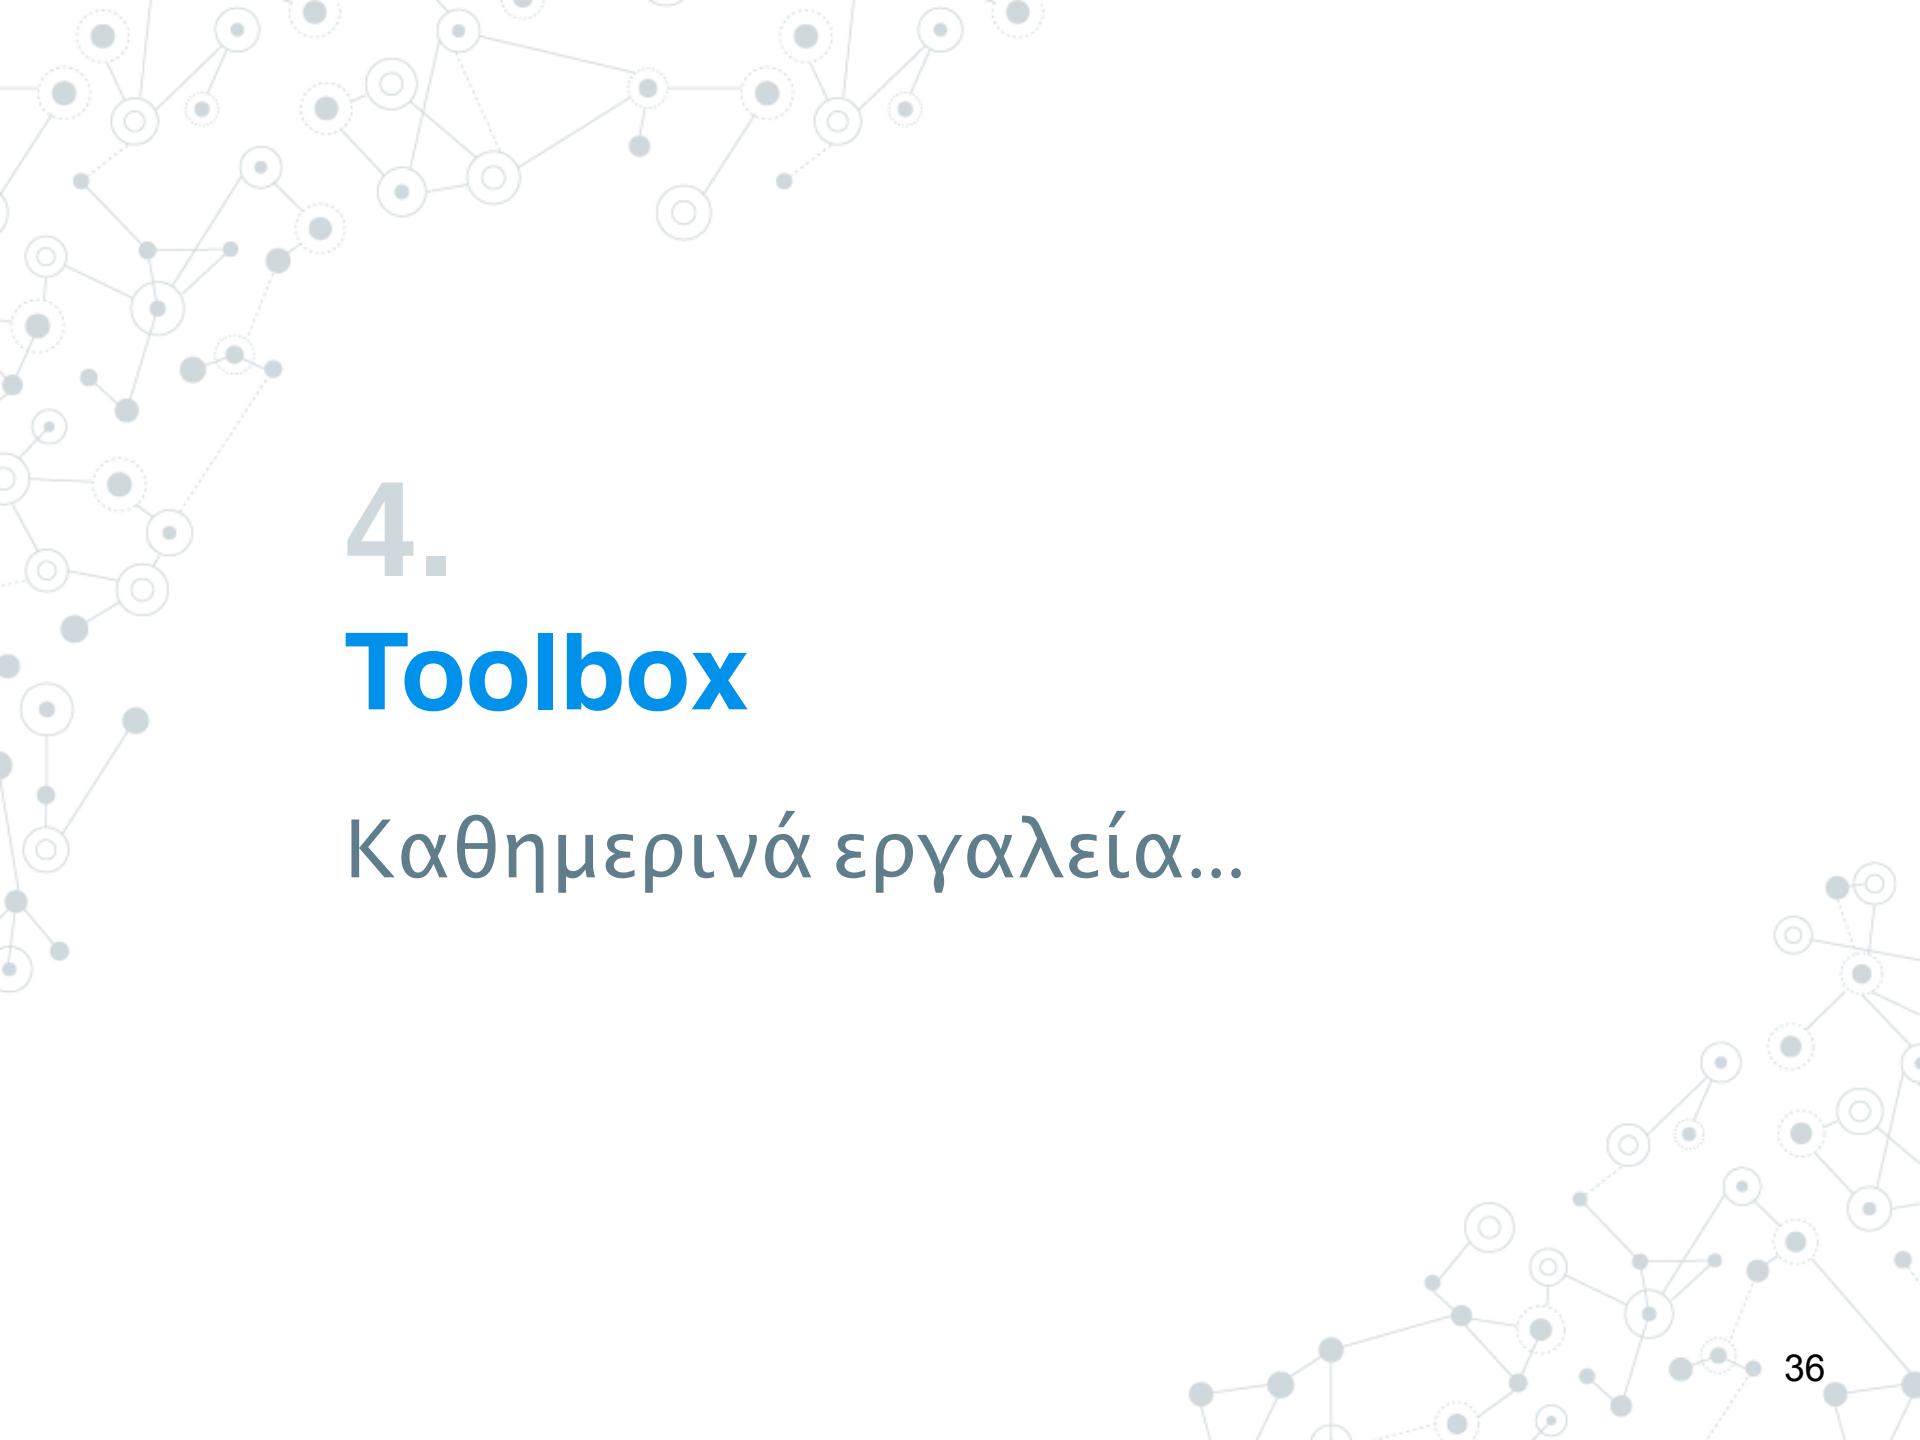
The math way

The tool way

Η αλήθεια στη μέση

Στην πράξη....





4. **Toolbox**

Καθημερινά εργαλεία...

Θα χρειαστείς...

- Git
- Virtual Machines
- Excel!!!!
- Python/R
- SQL

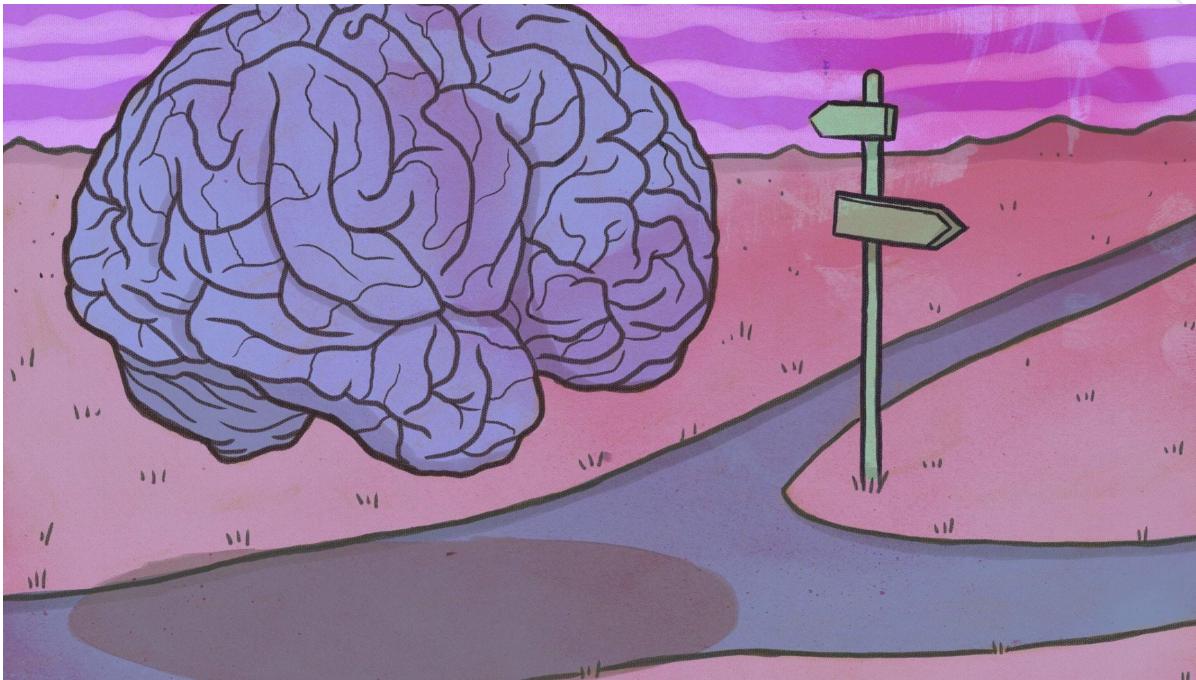
Extra:

- Dataiku
- Azure ML



Συμβουλή

#1

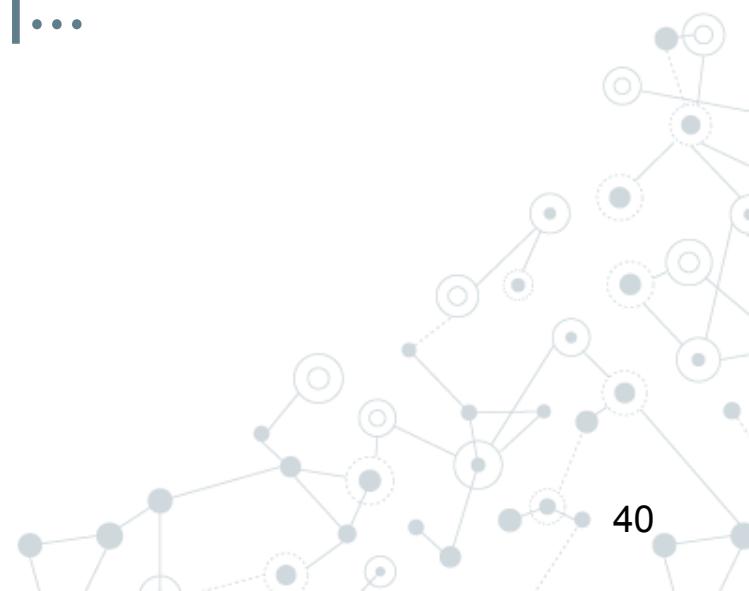


Μυαλό = Επεξεργασία & Αποφάσεις
Μυαλό ≠ Αποθήκευση



5. **Στατιστική**

Μια μικρή επανάληψη...



Έννοιες και η σημασία τους...

- ◎ **Τυχαίο δείγμα**

- ◎ **Μεταβλητές**

- **Κατηγορικές - Ποιοτικές**
 - Ονομαστική (χρώμα ματιών, τόπος γέννησης, φύλο)
 - Διάταξης (μορφωτικό επίπεδο, κλάσεις ηλικιών)
- **Ποσοτικές**
 - Διακριτή (πόσες σοκολάτες τρώω κάθε μέρα)
 - Συνεχής (το ύψος ανθρώπων)



Συμβουλή

#2

Κατηγορικές Μεταβλητές

Δεκαδικός αριθμός

\neq

Κατηγορική μεταβλητή

Μέτρα Θέσης

- ◎ Μέση τιμή (x)
- ◎ Διάμεσος (δ)
- ◎ Εύρος (R)
- ◎ Διακύμανση (s^2)
- ◎ Τυπική Απόκλιση (s)
- ◎ Συντελεστής Μεταβολής (s/x)



5. Python

Get our hands dirty!

Η επόμενη μέρα

- Git
- Data file types & Copyrights
- More Python (😍)
- Working on a Data Science Project
- Intro to Machine Learning

Thanks!

Any questions?